

## 1. 微调 (Fine-tuning on Pretrained LLM)

- 在已有的大模型 (Pretrained LLM) 上, 使用特定领域 (如法律) 的数据集进行额外的训练。
- 目的: 让模型更擅长理解和生成特定领域 (法律) 的语言、术语、格式和任务。
- 优点: 模型在特定任务上表现显著提升。
- 缺点: 需要高质量标注数据 (Labeled Data), 训练成本较高, 知识更新需要重新训练 (Often need to update the whole model, which may not be beneficial for other general tasks)。

## 2. RAG - Retrieval-Augmented Generation

- 在让 LLM 生成答案之前, 先从外部知识库 Database (如法律数据库、案例库、法规库) 中检索与问题相关的信息, 然后把检索到的信息片段和原始问题一起喂给大模型, 让它基于这些最新、可靠的信息来生成答案。
- 目的: **减少模型 Hallucination** (编造不存在或不准确的信息), 确保答案基于真实、最新的外部依据, 提高答案的可信度和准确性。特别适合需要引用具体条文、案例的场景。
- 类比: 律师在回答客户问题前, 先查阅法律条文和过往判例 (检索), 然后结合这些资料给出专业意见 (生成)。
- 优点: 知识更新快 (改知识库即可), 答案有据可查, 成本相对 Finetuning 较低。
- 缺点: 依赖外部知识库的质量和检索的准确性。
- **备注: 这个和 finetuning 一般是二选一,**

## 3. 向量数据库 (Vector Database)

- 一种专门设计用来高效存储、索引和搜索“向量” (Vector Embeddings) 的数据库。
- 向量嵌入 (Vector Embedding) 是什么? 由 AI 模型 (如嵌入模型 Embedding Models) 生成的、代表一段文本 (词、句、文档) 语义的一个 **Vector**。语义相近的文本, 其向量在空间中的距离也更近。

1. 文件 1 → 通过 Embedding Models → 生成一个高维的 Vector  $v1 = [1.1, 1.2, 0.9, -1]$
2. 文件 2 → 通过 Embedding Models → 生成一个高维的 Vector  $v2 = [0.9, 1.1, 0.4, -1.2]$
3. 如果文件 1 和文件 2 内容语义类似，那么  $v1$  和  $v2$  在向量空间中就比较接近，常见的指标是 cosine similarity → cosine similarity ( $v1, v2$ ) is high indicating that document 1 and document 2 are similar semantically.
  - 在 RAG 中的作用：是 RAG 架构中的核心组件。外部知识库（法律条文、案例）中的文档会被转换成向量并存储在向量数据库中。当用户提问时，问题也会被转换成向量，向量数据库通过计算向量相似度，快速找到与问题语义最相关的知识库文档片段，供 RAG 系统检索使用。
  - 目的：实现基于语义的快速相似性搜索，支撑 RAG 的高效检索。
  - 类比：一个超级高效的图书管理员，不是按书名或作者找书，而是能根据你问题的“意思”（语义）瞬间找到内容最相关的书籍段落。
  - 优点：搜索速度快（尤其在海量数据中），支持语义理解级别的搜索。
4. 提高模型 Accuracy / 减少 Hallucination 的一般方法
  - RAG is often used to reduce hallucination – LLM could cite or use known facts or documents retrieved from database to assist their task.
  - Fine-tuning is often used to improve accuracy: 使用高质量、特定领域的数据微调，让模型更熟悉领域知识和表达方式，减少在专业领域的胡说八道。
  - Prompt Engineering could also improve accuracy by including detailed instructions.
  - Verification 模型后处理/验证：对模型的输出进行额外检查，比如用规则校验关键信息（日期、法条号）、或用另一个（小）模型检查事实一致性。
  - Better Models: 通常，越新、参数越大的模型，幻觉相对越少，理解能力越强（但也更贵）。
  - Knowledge Graph 知识图谱集成：将模型与结构化的领域知识图谱连接，提供更准确的关系和事实约束。